



Università degli Studi di Cagliari

Facoltà di Ingegneria e Architettura

Corso di Laurea in Ingegneria

Elettrica-Elettronica-Informatica

Abstract della tesi di Laurea:

Elaborazione di segnale EEG e metodi di Machine Learning per la Motor Imagery Detection

Sommario

1. Introduzione.....	2
2. Dataset	3
3. Rappresentare i dati.....	3
4. Classificare i dati	4
5. Risultati, conclusioni e obiettivi futuri	5
Bibliografia.....	8

1. Introduzione

Questo lavoro di tesi è incentrato nello sviluppo di un algoritmo in grado di distinguere l'azione realmente svolta o solo pensata da un soggetto, utilizzando solo il segnale cerebrale registrato con la tecnica non invasiva EEG.

Questa tesi appartiene alla branca scientifica denominata Brain Computer Interface (abbreviata come BCI) [1] che, come suggerito dal nome, crea delle interfacce tra il cervello e la macchina. Le BCI sono utilizzate in molti campi come nelle neuroprotesi create per incidenti o malattie neurodegenerative [2], con la creazione di protesi come ad esempio braccia robotiche come illustrato in **Figura 1**. Le BCI si utilizzano anche in ambito educativo e sportivo [3]: grazie ai recenti studi sulla plasticità del cervello [4] e un'elettronica che consente di mandare dei feedback dalla macchina al cervello [5] è possibile migliorare le capacità cognitive del soggetto.

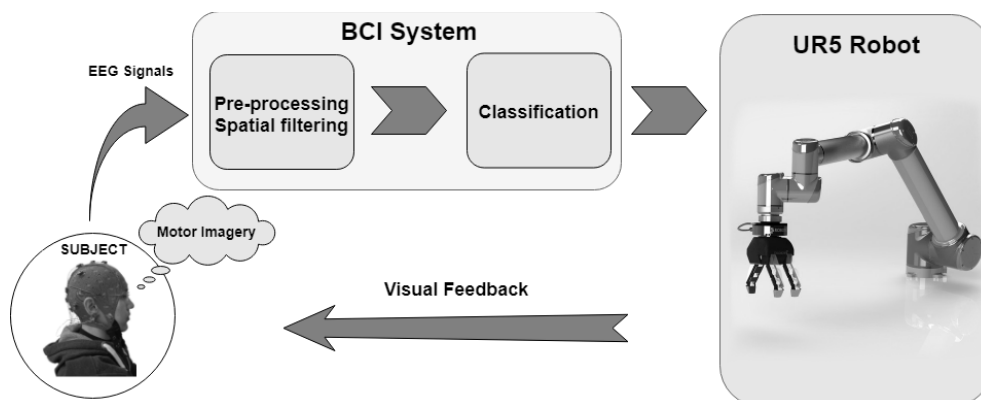


Figura 1: Schema tecnico di una BCI per inviare i movimenti a un braccio robotico e ricevere da questo un feedback tecnico – Fonte [6]

Per far sì che una BCI funzioni è necessario registrare il segnale cerebrale con tecniche invasive e non-invasive; successivamente il segnale viene elaborato, filtrato e si estraggono le feature, sulla base delle quali si effettua una classificazione per discriminare le azioni contenute in esso. Questi dati sono inviati a una CPU che attua di conseguenza: può solamente classificare l'azione, può svolgere l'azione e in alcuni casi può anche inviare un feedback al cervello per trasmettere la sensazione tattile.

Questo lavoro di tesi ha l'obiettivo di rispondere alle seguenti domande:

- È possibile con la tecnica EEG distinguere azioni immaginate o effettuate?
- Se sì, è possibile farlo per ogni azione e soggetto?
- Quanto la misura che lo rappresenta influisce sui risultati?

2. Dataset

Il dataset [7] utilizzato comprendeva 109 soggetti di età e sesso differenti, ognuno con 14 registrazioni cerebrali, 2 riguardanti il movimento oculare non oggetto di questo studio e le restanti 12 così suddivise:

- Macro-task A: apertura e chiusura del pugno sinistro (task 1) o destro (task 2)
- Macro-task B: immaginare apertura e chiusura del pugno sinistro (task 1) o destro (task 2)
- Macro-task C: chiusura di entrambi i pugni (task 1) o movimento di entrambi i piedi (task 2)
- Macro-task D: immaginare chiusura di entrambi i pugni (task 1) o movimento di entrambi i piedi (task 2)

3. Rappresentare i dati

Il segnale è stato analizzato nelle frequenze tra 7-30 Hz (bande dello stato attivo alfa e beta), suddiviso in periodi della durata di 1s (epoche). Su ogni epoca sono state applicate due misure:

- CSP [8] (Common Spatial Pattern, illustrato in **Figura 2**) per rappresentare il segnale in 4 dimensioni date dalla correlazione tra le varie caratteristiche del segnale. Questa rappresentazione si ottiene diagonalizzando la matrice di covarianza per ognuna delle due classi.

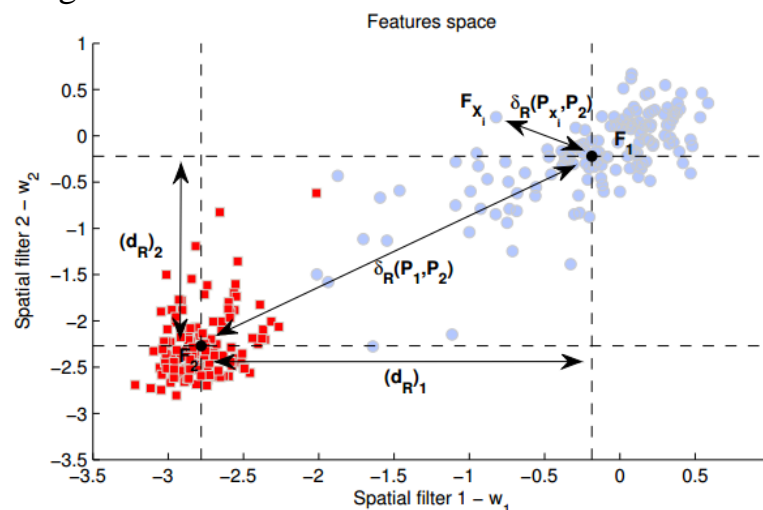


Figura 2: Illustrazione della misura CSP su 1 e 2 spazi in piano cartesiano – Fonte [8]

- FOOF [9] (Fitting Oscillations and One Over F, illustrato in **Figura 3**) per rappresentare il segnale in 128 dimensioni, 2 per ogni canale. Questi due parametri sono rispettivamente la pendenza della retta del segnale aperiodico e la sua intercetta. Il segnale aperiodico è una componente della densità dello spettro di potenza del segnale e secondo [9] contiene più informazioni sul

segnale rispetto alla componente periodica, fornendo un'alternativa allo studio in banda. Su questa misura è stata effettuata una selezione dei canali: inizialmente è stato analizzato il segnale raccolto da tutti i 64 elettrodi presenti nello scalpo; successivamente sono stati selezionati solo i 29 canali corrispondenti alla corteccia motoria e premotoria, le zone cerebrali dove si origina il segnale nervoso per il movimento [10].

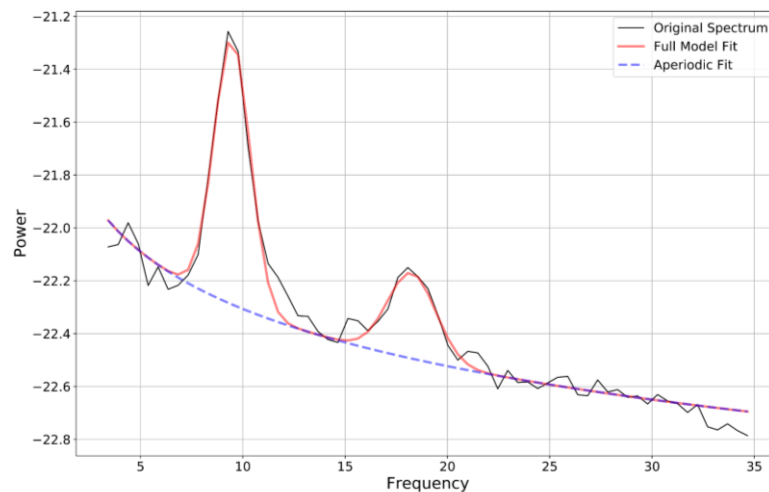


Figura 3: Risultato finale dell'implementazione della misura FOOOF – Fonte [9]

4. Classificare i dati

Sulla base di questi dati è stata effettuata una classificazione [11] utilizzando gli algoritmi di kNN (attribuisce al campione la classe in base alla classe maggioritaria dei k campioni di train più vicini) e LDA (trova una superficie di separazione tra le due classi).

Per effettuare una classificazione è necessario suddividere i dati in una parte di train per addestrare il classificatore e una di test per controllare il comportamento. Sono state utilizzate tre diverse metodiche di separazione dei dati, illustrate in **Figura 4**:

- **Hold-out:** concatenando le 3 registrazioni per ogni macro-run, campionando randomicamente il 20% come test set, ripetendolo 10 volte. Per testare la robustezza dell'algoritmo si è successivamente scelta come dimensione del test set 80%, sempre randomicamente e ripetendolo 10 volte.
- **Tecnica dei run:** applicata per capire se tra le tre registrazioni di uno stesso macro-task siano presenti delle differenze dovute al diverso momento di registrazione (cambiamento di umore o concentrazione nella persona o aggiunta di rumore ambientale o strumentale). Per tanto, è stato svolto il train su due registrazioni dello stesso macro-task e, sempre per verificare la robustezza dell'algoritmo, successivamente il train su una sola registrazione.

- Leave-one-out: questa è una situazione di studio più facile, in cui è stato selezionato un campione di ogni registrazione come test set, avendo precedentemente addestrato il classificatore sui restanti campioni.

Con il dataset utilizzato i risultati non cambiano a seconda della suddivisione scelta.

Infine, si è effettuata una tecnica di clusterizzazione utilizzando l'algoritmo di k-means, senza però ottenere gruppi completamente omogenei. Con questi dati non è possibile creare dei cluster contenenti campioni della stessa azione.

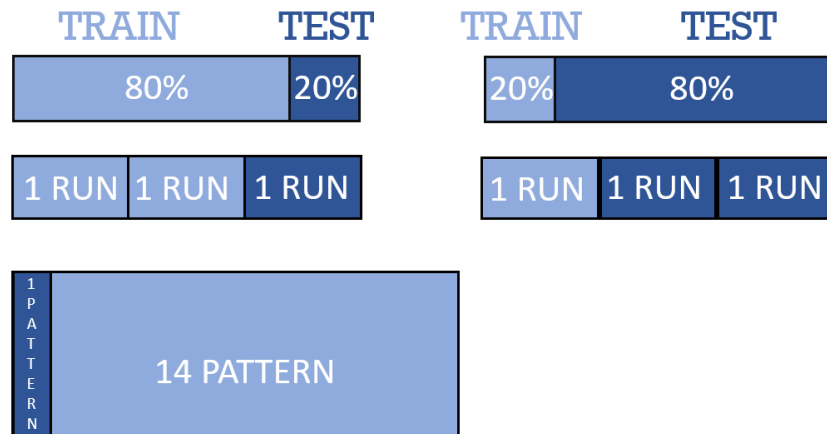


Figura 4: Illustrazione delle 3 suddivisioni dei dati. Dall'alto verso il basso: 1. Hold-out con test al 20% e 80%, 10 ripetizioni. 2. Tecnica dei run: 1 e 2 run di test, 3 ripetizioni con le 3 combinazioni di run per train e successivamente per test. 3. Leave-one-out: 1 solo pattern per il test, 15 ripetizioni selezionando 1 pattern alla volta per il test

5. Risultati, conclusioni e obiettivi futuri

Con i dati utilizzati in questo studio non è possibile notare una differenza tra l'accuratezza media nella classificazione di ogni macro-task utilizzando i due diversi classificatori. Col termine accuratezza media si intende il valore di accuratezza mediato tra tutti i 109 soggetti. L'accuratezza di ogni soggetto è ottenuta mediando il valore di accuratezza ottenuto in ogni algoritmo per tutte le ripetizioni (10 volte nel caso di hold-out, 3 volte nel caso del test con i run, 15 volte nel caso del leave-one-out). In questi esperimenti dunque, scegliere un classificatore kNN piuttosto che un LDA non migliora le performance, risultato illustrato in **Figura 5**.

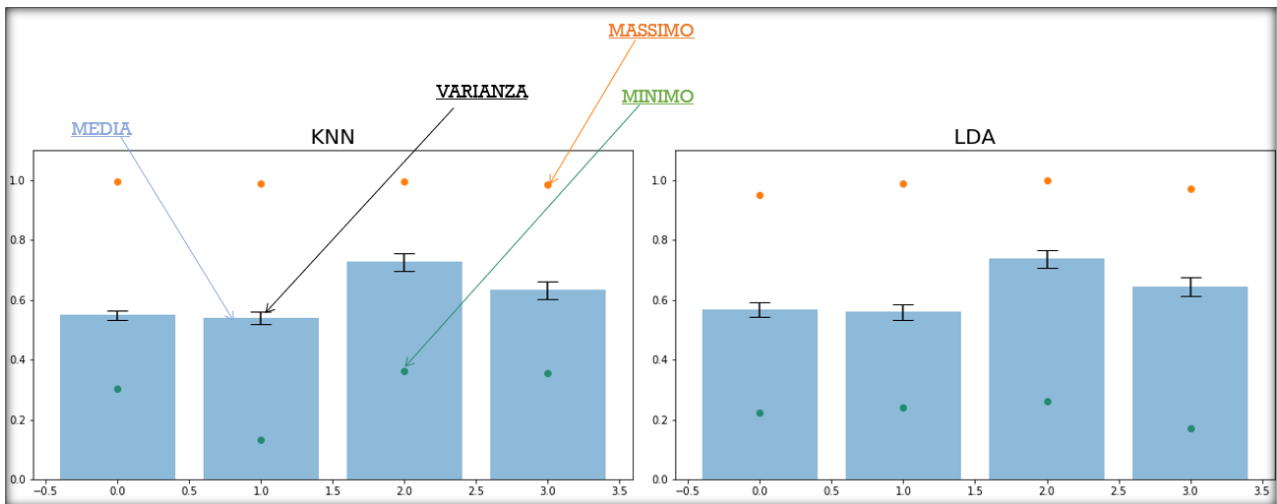


Figura 5: Illustrazione dei valori di accuratezza media per kNN e LDA con la misura CSP

Si può invece affermare come la misura abbia una forte influenza, illustrazione in **Figura 6**. Nonostante l'accuratezza media non sia elevata in nessuno dei 4 macro-task di nessuna delle 3 misure, con la misura CSP per alcuni soggetti in alcuni macro-task è stata registrata un'accuratezza pari a 1.0 in entrambi i classificatori.

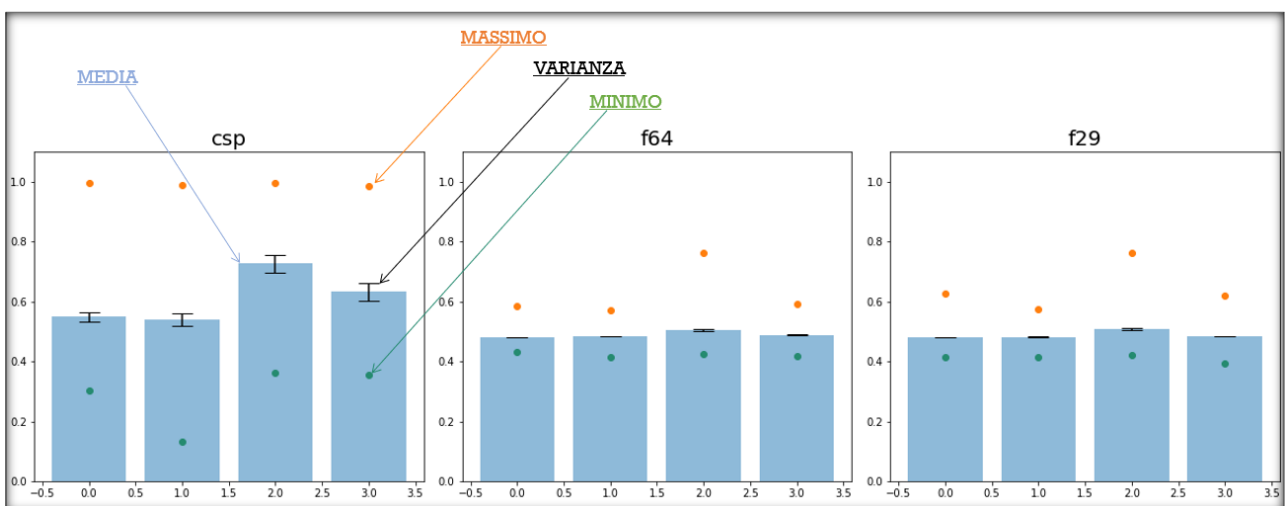


Figura 6: Illustrazione dei valori di accuratezza media per le 3 diverse misure. Da sinistra verso destra: CSP, FOOOF a 64 canali, FOOOF a 29 canali

Dopo queste osservazioni, si può stabilire se gli esperimenti fossero user specific, ovvero se il livello di accuratezza dipenda da ogni soggetto. Per ogni macro-task esistono dei soggetti con valori di accuratezza molto bassi (circa 0.4) e altri soggetti nello stesso macro-task presentano accuratezza pari a 1.0. Applicando [12] ai dati di questa tesi, si può affermare che dal valore di accuratezza 0.8 in poi, l'accuratezza ottenuta non è dovuta al caso ma al numero di pattern presenti nel dataset. Si può dunque affermare che per i soggetti per cui l'algoritmo riporta valore di accuratezza maggiore o uguale a 0.8 per quel preciso macro-task, non è casuale ma veramente l'algoritmo classifica accuratamente il segnale prodotto da quel soggetto. Con i dati utilizzati in questa tesi, lo studio è user specific, risultato illustrato in **Figura 7**.

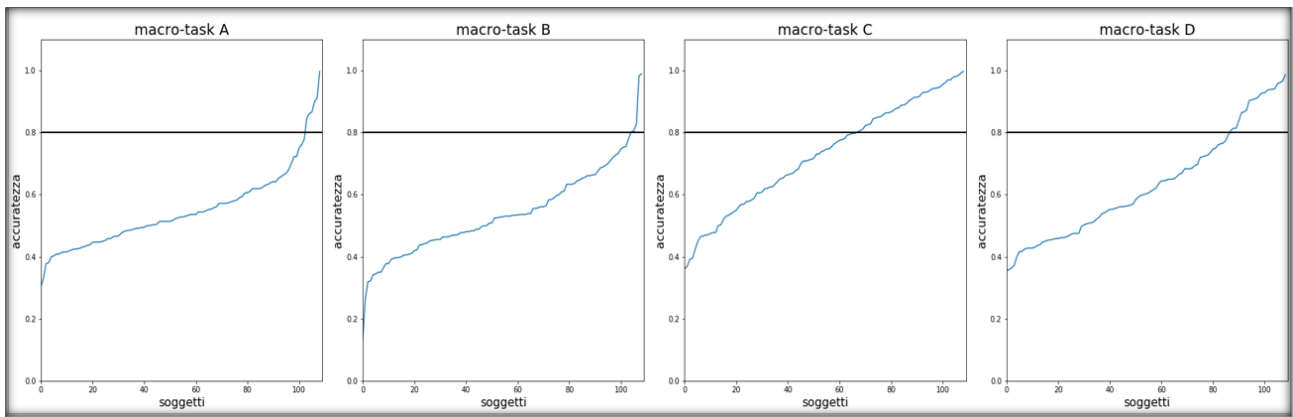


Figura 7: Illustrazione user specific. Esiste un gruppo di soggetti con accuratezza maggiore o uguale a 0.8 (linea orizzontale) per cui l'algoritmo funziona bene ma non è dovuto al caso

L'andamento è anche task specific? Ovvero un soggetto con accuratezza elevata in un task ha lo stesso valore di accuratezza in un altro task? Su 6 soggetti (persone con accuratezza maggiore o uguale a 0.8 per il macro-task A), solo uno di questi ha avuto accuratezza maggiore o uguale a 0.8 anche nei restanti tre macro-task, illustrazione in **Figura 8**.

Soggetti	macro-run A	macro-run B	macro-run C	macro-run D
19	0.847	0.636	0.931	0.728
49	0.861	0.597	0.914	0.747
54	0.867	0.747	0.847	0.808
42	0.9	0.728	0.903	0.942
7	0.911	0.989	0.997	0.928
46	0.997	0.469	0.947	0.603

Figura 8: Illustrazione task specific. Sono mostrati nella prima colonna a sinistra i 6 soggetti con valore di accuratezza maggiore o uguale a 0.8 nel macro-task A e i valori di accuratezza per gli stessi soggetti negli altri tre macro-task. Solo il soggetto 7 presenta un'accuratezza elevata in tutti i quattro macro-task. Il sistema è user specific e task specific.

Concludendo possiamo affermare come per questi esperimenti la misura utilizzata sia di fondamentale importanza e la migliore risulta la CSP. Il sistema sviluppato è task specific e user specific. Questi ultimi sono dei risultati attesi poiché non si può creare una brain computer interface universale per ogni persona esistente al mondo e per ogni tipo di azione.

Questo lavoro potrebbe essere ampliato studiando i segnali con diverse misure, utilizzare diverse tecniche per la selezione dei canali, scegliere diverse coppie discriminanti (ad esempio tra i vari macro-task anziché le due azioni di ogni macro-task) e utilizzare altri dataset più ricchi di campioni.

Bibliografia

- [1] M. Alimardani, S. Nishio, e H. Ishiguro, «Brain-Computer Interface and Motor Imagery Training: The Role of Visual Feedback and Embodiment», *Evol. BCI Ther. - Engag. Brain State Dyn.*, ott. 2018, doi: 10.5772/intechopen.78695.
- [2] L. A. Farwell e E. Donchin, «Talking off the top of your head: toward a mental prosthesis utilizing event-related brain potentials», *Electroencephalogr. Clin. Neurophysiol.*, vol. 70, n. 6, pagg. 510–523, dic. 1988, doi: 10.1016/0013-4694(88)90149-6.
- [3] Y. Popat e A. Kaur, «Critical Review and Study of Brain Wave Acquisition and Applications & Challenges of Brain Machine Interfacing», *Inf. Technol.*, vol. 6, n. 6, pag. 8, 2017.
- [4] T. Nierhaus, C. Vidaurre, C. Sannelli, K.-R. Mueller, e A. Villringer, «Immediate brain plasticity after one hour of brain–computer interface (BCI)», *J. Physiol.*, vol. n/a, n. n/a, doi: 10.1113/JP278118.
- [5] L. E. H. van Dokkum, T. Ward, e I. Laffont, «Brain computer interfaces for neurorehabilitation – its current status as a rehabilitation strategy post-stroke», *Ann. Phys. Rehabil. Med.*, vol. 58, n. 1, pagg. 3–8, feb. 2015, doi: 10.1016/j.rehab.2014.09.016.
- [6] BatyaGG, *BatyaGG/BCI-controlled-UR-manipulator*. 2020.
- [7] Goldberger Ary L. *et al.*, «PhysioBank, PhysioToolkit, and PhysioNet», *Circulation*, vol. 101, n. 23, pagg. e215–e220, giu. 2000, doi: 10.1161/01.CIR.101.23.e215.
- [8] A. Barachant, S. Bonnet, M. Congedo, e C. Jutten, «Common Spatial Pattern revisited by Riemannian Geometry», in *2010 IEEE International Workshop on Multimedia Signal Processing (MMSP)*, St-Malo, France, ott. 2010, pag. 472, doi: 10.1109/MMSP.2010.5662067.
- [9] M. Haller *et al.*, «Parameterizing neural power spectra», *bioRxiv*, pag. 299859, apr. 2018, doi: 10.1101/299859.
- [10] J. Meng, S. Zhang, A. Bekyo, J. Olsoe, B. Baxter, e B. He, «Noninvasive Electroencephalogram Based Control of a Robotic Arm for Reach and Grasp Tasks», *Sci. Rep.*, vol. 6, dic. 2016, doi: 10.1038/srep38565.
- [11] «Webb A.R., Copsey K.D. Statistical Pattern Recognition [PDF]». <https://www.twirpx.com/file/1029836/> (consultato set. 25, 2020).
- [12] E. Combrisson e K. Jerbi, «Exceeding chance level by chance: The caveat of theoretical chance levels in brain signal classification and statistical assessment of decoding accuracy», *J. Neurosci. Methods*, vol. 250, pagg. 126–136, lug. 2015, doi: 10.1016/j.jneumeth.2015.01.010.